

WYDZIAŁ INFORMATYKI I TELEKOMUNIKACJI
Instytut Informatyki

Praca dyplomowa magisterska

**ANALIZA RUCHU SIECIOWEGO APLIKACJI MOBILNYCH NA
PLATFORMIE ANDROID**

Imię Nazwisko, nr albumu 123456Imię Nazwisko, 123456

Promotor
dr inż. Imię Nazwisko

POZNAŃ 2025

Streszczenie

Przedmiotem pracy jest analiza ruchu sieciowego generowanego przez wybrane aplikacje mobilne systemu Android. Zaimplementowano środowisko przechwytywania (mitmproxy, tcpdump), normalizacji i klasyfikacji z uwzględnieniem protokołów (HTTP/1.1, HTTP/2, QUIC), szyfrowania TLS oraz aspektów prywatności (domeny trackingowe, identyfikatory). Wyniki obejmują statystyki protokołów, charakterystykę ruchu według kategorii aplikacji oraz ocenę ryzyk potencjalnego ujawniania metadanych.

Słowa kluczowe: Android, analiza ruchu, TLS, QUIC, prywatność, mitmproxy.

Abstract

This thesis investigates network traffic generated by selected Android applications. A modular environment for traffic interception (mitmproxy, tcpdump), normalization and classification was implemented, focusing on protocols (HTTP/1.1, HTTP/2, QUIC), TLS encryption and privacy aspects (tracking domains, identifiers). Results include protocol usage statistics, traffic characteristics across app categories, and an assessment of potential metadata exposure risks.

Keywords: Android, network traffic analysis, TLS, QUIC, privacy, mitmproxy.

Spis treści

Spis rysunków	5
Spis tabel	7
Spis listingów	11
Wykaz skrótów	13
1 Wstęp	15
1.1 Motywacja	15
1.2 Cel i zakres pracy	15
1.3 Pytania badawcze i hipotezy	15
1.4 Metody i podejście	15
1.5 Struktura pracy	15
2 Przegląd literatury i technologii	17
2.1 Architektura systemu Android	17
2.2 Model bezpieczeństwa	17
2.3 Protokoły	17
2.4 Techniki analizy ruchu	17
2.5 Prywatność i tracking	17
2.6 Powiązane badania	17
3 Metodyka badawcza	19
3.1 Kryteria doboru aplikacji	19
3.2 Środowisko testowe	19
3.3 Procedura przechwytywania	19
3.4 Automatyzacja interakcji	19
3.5 Model danych i metryki	19
3.6 Anonimizacja i etyka	19
3.7 Walidacja	19
4 Architektura rozwiązania	21
4.1 Przegląd komponentów	21
4.2 Diagram wysokopoziomowy	21
4.3 Przepływ danych (ETL)	21
4.4 Struktura repozytorium	21
4.5 Model normalizacji	21
4.6 Rozszerzalność	21

5	Implementacja	23
5.1	Moduł przechwytywania	23
5.2	Hooki mitmproxy	23
5.3	Parser i normalizacja	23
5.4	Klasyfikacja domen	23
5.5	Agregacje i raporty	23
5.6	Testy	23
6	Eksperymenty i wyniki	25
6.1	Plan eksperymentalny	25
6.2	Charakterystyka próbek	25
6.3	Wykorzystanie protokołów	25
6.4	Analiza domen trackingowych	25
6.5	Czasy odpowiedzi i rozmiary	25
6.6	Ograniczenia	25
7	Aspekty bezpieczeństwa i prywatności	27
7.1	Szyfrowanie i wersje TLS	27
7.2	Certificate pinning	27
7.3	Potencjalne wycieki metadanych	27
7.4	Domeny trackingowe	27
7.5	Implikacje	27
8	Dyskusja	29
8.1	Interpretacja wyników	29
8.2	Porównanie z literaturą	29
8.3	Zagrożenia dla ważności	29
8.4	Perspektywa praktyczna	29
9	Wnioski i dalsze prace	31
9.1	Podsumowanie	31
9.2	Odpowiedzi na pytania badawcze	31
9.3	Możliwe rozszerzenia	31
A	Dodatkowe wykresy	33
B	Konfiguracja środowiska	35
B.1	Parametry mitmproxy	35
B.2	Skrypt automatyzacji ADB (fragment)	35
B.3	Struktura katalogów danych	35

Spis rysunków

4.1	Architektura modułowa środowiska analitycznego (schemat).	21
-----	---	----

Spis tabel

Spis algorytmów

Spis listingów

1	Hook mitmproxy zapisujący metadane żądań	23
---	--	----

Wykaz skrótów

API – Application Programming Interface
TLS – Transport Layer Security
HTTP – HyperText Transfer Protocol
QUIC – Quick UDP Internet Connections
CDN – Content Delivery Network
DNS – Domain Name System
ADB – Android Debug Bridge

Rozdział 1

Wstęp

1.1 Motywacja

Ekosystem aplikacji mobilnych rozwija się dynamicznie: rośnie złożoność warstw komunikacyjnych (HTTP/2, QUIC), wzmacnia się szyfrowanie (TLS 1.3) i presja regulacyjna dotycząca prywatności. Użytkownicy mają ograniczoną widoczność tego, jakie dane i do jakich domen są wysyłane.

1.2 Cel i zakres pracy

Cel: Opracowanie oraz ewaluacja środowiska do systematycznej analizy ruchu sieciowego aplikacji Android i identyfikacji wzorców komunikacyjnych oraz ryzyk prywatności.

Zakres obejmuje: (i) przygotowanie środowiska do przechwytywania, (ii) normalizację i klasyfikację ruchu, (iii) zdefiniowanie metryk, (iv) eksperymenty na wybranym zbiorze aplikacji, (v) analizę protokołów i domen trackingowych.

1.3 Pytania badawcze i hipotezy

Pytanie badawcze: Jakie protokoły transportowe dominują w ruchu popularnych aplikacji?
Hipoteza: Ponad 60% żądań wykorzystuje HTTP/2 lub QUIC.

Pytanie badawcze: Czy aplikacje multimedialne kierują większy odsetek ruchu do domen analitycznych niż komunikatory?

Hipoteza: Aplikacje multimedialne wykazują wyższy udział żądań do domen trackingowych.

1.4 Metody i podejście

Krótki opis strategii: obserwacja black-box, przechwytywanie TLS z wstrzykniętym CA, heurystyki klasyfikacji domen, pomiar i agregacje.

1.5 Struktura pracy

Opis zawartości kolejnych rozdziałów (skrót).

Rozdział 2

Przegląd literatury i technologii

2.1 Architektura systemu Android

Krótką charakterystyka warstw (kernel, HAL, ART, framework). Odniesienia do dokumentacji.

2.2 Model bezpieczeństwa

Sandbox, uprawnienia, Store review, mechanizmy ograniczające przechwytywanie (certificate pinning).

2.3 Protokoły

HTTP/1.1, HTTP/2 (multiplexing), HTTP/3/QUIC (UDP, 0-RTT), TLS 1.3 skrócenie handshake [1], [2].

2.4 Techniki analizy ruchu

Narzędzia: tcpdump, Wireshark, mitmproxy, Frida (hookowanie), emulator vs urządzenie fizyczne.

2.5 Prywatność i tracking

Mechanizmy identyfikacji użytkownika, rola domen reklamowych, fingerprinting.

2.6 Powiązane badania

Syntetyczne zestawienie publikacji – wykazać luki (np. niedostateczna analiza QUIC w mobilnych aplikacjach konsumenckich).

Rozdział 3

Metodyka badawcza

3.1 Kryteria doboru aplikacji

Popularność (rankingi store), kategorie (komunikacja, multimedia, finanse), aktualność wersji.

3.2 Środowisko testowe

Sprzęt (model urządzenia), wersja Android, konfiguracja sieci (oddzielony SSID), kontrola tła (tryb samolotowy przed startem sesji).

3.3 Procedura przechwytywania

Instalacja certyfikatu CA dla mitmproxy, konfiguracja proxy systemowego, ograniczenia w wypadku pinningu.

3.4 Automatyzacja interakcji

Skrypty ADB / uiautomator generujące sekwencje działań, logowanie timestampów.

3.5 Model danych i metryki

Pola: timestamp, host, ścieżka, metoda, kod statusu, rozmiary (request/response), protokół (HTTP/2 / QUIC), kategoria domeny, czas odpowiedzi.

3.6 Anonimizacja i etyka

Hashowanie identyfikatorów, odrzucanie payloadów binarnych zawierających potencjalne dane osobowe, brak logowania treści formularzy.

3.7 Walidacja

Losowa weryfikacja spójności liczby pakietów vs liczby zarejestrowanych żądań; test powtarzalności (2 przebiegi).

Rozdział 4

Architektura rozwiązania

4.1 Przegląd komponentów

Opis modułów: przechwytywanie, ekstrakcja, normalizacja, klasyfikacja, agregacja, wizualizacja.

4.2 Diagram wysokopoziomowy

RYSUNEK 4.1: Architektura modułowa środowiska analitycznego (schemat).

4.3 Przepływ danych (ETL)

Kolejne etapy: capture -> parse -> enrich -> store -> stats.

4.4 Struktura repozytorium

Opis katalogów (np. scripts/, data/, analysis/).

4.5 Model normalizacji

Mapowanie surowych atrybutów mitmproxy na ujednolicony rekord JSON/CSV.

4.6 Rozszerzalność

Dodanie nowego klasyfikatora domen lub obsługa innego proxy.

Rozdział 5

Implementacja

5.1 Moduł przechwytywania

Konfiguracja mitmproxy, parametry uruchomienia.

5.2 Hooki mitmproxy

```
1 def response(flow):
2     rec = {
3         "proto": flow.request.scheme,
4         "host": flow.request.host,
5         "path": flow.request.path,
6         "method": flow.request.method,
7         "status": flow.response.status_code,
8         "t_start": flow.request.timestamp_start,
9         "t_end": flow.request.timestamp_end,
10        "length": len(flow.response.raw_content or b"")
11    }
12    save_record(rec)
```

LISTING 1: Hook mitmproxy zapisujący metadane żądań

5.3 Parser i normalizacja

Krok po kroku: walidacja, cast typów, uzupełnianie braków.

5.4 Klasyfikacja domen

Listy znanych trackerów, heurystyki (substring, kategorie TLD, reverse DNS).

5.5 Agregacje i raporty

Obliczanie histogramów, percentyle czasów odpowiedzi.

5.6 Testy

Testy jednostkowe (poprawność mapowania), testy integracyjne (ciąg ETL).

Rozdział 6

Eksperymenty i wyniki

6.1 Plan eksperymentalny

Opis serii sesji, długość, liczba powtórzeń.

6.2 Charakterystyka próbek

Liczba aplikacji, łączna liczba żądań, udział kategorii.

6.3 Wykorzystanie protokołów

Tabela i wykres udziału HTTP/1.1 vs HTTP/2 vs QUIC.

6.4 Analiza domen trackingowych

Odsetek żądań do trackerów per kategoria.

6.5 Czasy odpowiedzi i rozmiary

Rozkłady, mediany, percentyle.

6.6 Ograniczenia

Próbkowanie krótkich okien użycia, brak tła push/pull w długim horyzoncie.

Rozdział 7

Aspekty bezpieczeństwa i prywatności

7.1 Szyfrowanie i wersje TLS

Wykryte wersje, renegotjacje (jeśli obserwowane).

7.2 Certificate pinning

Przypadki utraty widoczności ruchu (fail-open / fail-closed), wpływ na wyniki.

7.3 Potencjalne wycieki metadanych

Parametry w URL, identyfikatory urządzeń, tokeny.

7.4 Domeny trackingowe

Porównanie intensywności ruchu do domen analitycznych.

7.5 Implikacje

Ryzyka dla prywatności użytkownika i rekomendacje (np. ograniczanie uprawnień sieciowych, firewall lokalny).

Rozdział 8

Dyskusja

8.1 Interpretacja wyników

W jakim stopniu dane potwierdzają/obalają hipotezy.

8.2 Porównanie z literaturą

Zestawienie różnic (np. wzrost QUIC vs wcześniejsze badania).

8.3 Zagrożenia dla ważności

Internal: artefakty środowiska testowego; external: różnice regionów geograficznych; konstrukcja: wybór kategorii.

8.4 Perspektywa praktyczna

Wartość dla użytkowników, deweloperów, regulatorów.

Rozdział 9

Wnioski i dalsze prace

9.1 Podsumowanie

Najważniejsze osiągnięcia i wkład.

9.2 Odpowiedzi na pytania badawcze

Zwięzłe odpowiedzi w punktach.

9.3 Możliwe rozszerzenia

Automatyczna detekcja anomalii, uczenie maszynowe do klasyfikacji domen, analiza korelacji z zużyciem energii.

Dodatek A

Dodatkowe wykresy

Dodatkowe wizualizacje (np. szczegółowe histogramy czasów odpowiedzi, rozkłady rozmiarów payloadów).

Dodatek B

Konfiguracja środowiska

B.1 Parametry mitmproxy

```
mitmproxy --mode regular --set connection_strategy=lazy
```

B.2 Skrypt automatyzacji ADB (fragment)

Przykład sekwencji wejść użytkownika generowanych sztucznie.

B.3 Struktura katalogów danych

Opis: raw/ processed/ reports/.

Imię Nazwisko (2025)

Instytut Informatyki, Wydział Informatyki i Telekomunikacji
Politechnika Poznańska

Skład przy użyciu systemu L^AT_EX (Overleaf).